# Eshimova Xurshidaning imtihon vazifasi hisoboti

1-vazifa. Biznes muammosini tushunish:

- **1.1.** Nima uchun kompaniya uchun mijoz ketishini oldindan bilish muhim? Mijoz ketishi bu kompaniya xizmatidan mijozning butunlay voz kechishidir. Uni oldindan aniqlash juda muhim, chunki:
  - Koʻp mijozlar ketadigan boʻlsa, kompaniyaning daromadi tushib ketadi.
  - Oldindan xavfli mijozlarni aniqlab, ular bilan individual ish olib borish mumkin chegirmalar, maxsus takliflar orqali.
- 1.2. Qaysi turdagi mijozlar "xavfli" toifaga kiradi?

Tahminan quyidagi mijozlar "xavfli" ya'ni ketish ehtimoli katta bo'lgan mijozlar deb qarash mumkin.

- Yangi roʻyxatdan oʻtgan, lekin kam foydalangan;
- Har oy oʻzi toʻlov qiladigan, avto-toʻlovdan foydalanmaydiganlar;
- Har oyda juda kam miqdorda yoki aksincha juda ko'p miqdorda to'lov qilayotgan mijozlar.

**2-vazifa:** Ma'lumotlarni tahlil qilish va gipotezalarni tekshirish.

**2.1.** Dastlabki ma'lumotlarda 21 ta ustun mavjud bo'lib, bo'sh qoldirilgan ma'lumotlar, anomaliyalar mavjud edi va datasetni tozalash lozim.

Umumiy o'lcham: df.shape

Ustun nomlari va turlari: <a href="df.info">df.info</a>()

Yetishmayotgan qiymatlar: df.isnull().sum()

- **2.2.** Kamida 3 ta gipoteza taklif qiling va statistik usullar bilan tekshiring:
  - Masalan, yangi mijozlar koʻproq ketadimi?

Nol gipoteza (H<sub>0</sub>):

Ketgan mijozlar va qolgan mijozlarning xizmatdan foydalanish davomiyligi oʻrtacha bir xil (ya'ni yangi yoki eskiligi farq qilmaydi).

Alternativ gipoteza (H<sub>1</sub>):

Ketgan mijozlar xizmatdan kamroq muddat foydalanishgan (ya'ni ular yangi mijozlar bo'lgan).

Bu gipotezani Student's t-test orqali tahlil qilamiz.

```
import pandas as pd
from scipy import stats

ketgan = df[df['Churn'] == 'Yes']['tenure']

qolgan = df[df['Churn'] == 'No']['tenure']

t_stat, p_value = stats.ttest_ind(ketgan, qolgan, equal_var=False)

print("T-statistic:", t_stat)
print("P-value:", p_value)

v 0.0s

T-statistic: -32.682351268198886
P-value: 4.374068567142151e-209
```

## **P-value = 4.37e-209** bu degani:

- Bu qiymat **0.05 dan ancha kichik** (hatto  $\approx 0$  ga teng);
- Ya'ni, nol gipotezani (H<sub>0</sub>) qat'iyan rad qilamiz.

### T-statistic: -32.68

- **Salbiy chiqdi** bu shuni anglatadiki, ketgan mijozlarning oʻrtacha "tenure" (xizmat davomiyligi) qolganlarnikidan ancha kichik.
- Ya'ni ular ko'proq yangi mijozlar.

Demak yangi mijozlar ko'proq tark etishmoqda.

- Internet xizmatidan foydalanuvchilar koʻproq ketadimi? Gipotezalarni aniqlash:
- H<sub>0</sub> (nol gipoteza): Internet xizmat turi va mijoz ketishi oʻrtasida bogʻliqlik yoʻq
- H<sub>1</sub> (muqobil gipoteza): Internet xizmat turi va mijoz ketishi oʻrtasida bogʻliqlik bor

InternetService" (internet turi) bilan "Churn" (xizmatdan ketish) oʻrtasidagi bogʻliqlik Chi-kvadrat testi yordamida tahlil qilindi.

Natijalarga koʻra, internet turi mijoz ketishiga sezilarli ta'sir koʻrsatadi. Ayniqsa, Fiber optic xizmatidan foydalanuvchilar orasida xizmatdan voz kechish holatlari koʻproq kuzatildi.

```
1 import pandas as pd
   2 from scipy.stats import chi2_contingency
   4 df = df[['InternetService', 'Churn']].dropna()
  5 table = pd.crosstab(df['InternetService'], df['Churn'])
  7 chi2, p, dof, expected = chi2_contingency(table)
  8 print("Chi-squared:", chi2)
  9 print("P-value:", p)
  10 print("Degrees of Freedom:", dof)
  11 print("\nContingency Table:\n", table)
Chi-squared: 732.309589667794
P-value: 9.571788222840544e-160
Degrees of Freedom: 2
Contingency Table:
                 No Yes
InternetService
DSL
               1962 459
Fiber optic
               1799 1297
                1413 113
```

# - Ayollar kamroq ketadimi?

Gipotezalarni aniqlash:

- **H**<sub>0</sub> (nol gipoteza): Mijozning jinsi (gender) va xizmatdan ketishi (Churn) oʻrtasida bogʻliqlik yoʻq
- **H**<sub>1</sub> (muqobil gipoteza): Mijozning jinsi va xizmatdan ketishi oʻrtasida bogʻliqlik bor

```
1 import pandas as pd
   2 from scipy.stats import chi2 contingency
   3 df gender churn = df[['gender', 'Churn']].dropna()
   5 table = pd.crosstab(df_gender_churn['gender'], df_gender churn['Churn'])
   6 chi2, p, dof, expected = chi2_contingency(table)
   7 print("Chi-squared:", chi2)
   8 print("P-value:", p)
  9 print("Degrees of Freedom:", dof)
  10 print("\nContingency Table:\n", table)
✓ 0.0s
Chi-squared: 0.4840828822091383
P-value: 0.48657873605618596
Degrees of Freedom: 1
Contingency Table:
Churn
        No Yes
gender
Female 2549 939
Male
       2625 930
```

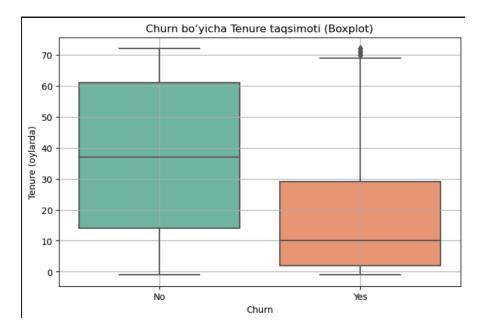
Chi-kvadrat testi natijalariga koʻra, mijozning jinsi (gender) bilan xizmatdan voz kechishi (Churn) oʻrtasida statistik ahamiyatga ega bogʻliqlik aniqlanmadi ( $\chi^2$  = 0.484, df = 1, p = 0.487). Bu esa ayol va erkak mijozlar orasida ketish ehtimoli deyarli bir xil ekanini koʻrsatadi.

## 3-vazifa. Vizualizatsiya:

3.1. tenure (kompaniyada qolish muddati) boʻyicha Churn taqsimoti

```
import matplotlib.pyplot as plt
import seaborn as sns
plt.figure(figsize=(8, 5))
sns.boxplot(x='Churn', y='tenure', data=df,
palette='Set2')
```

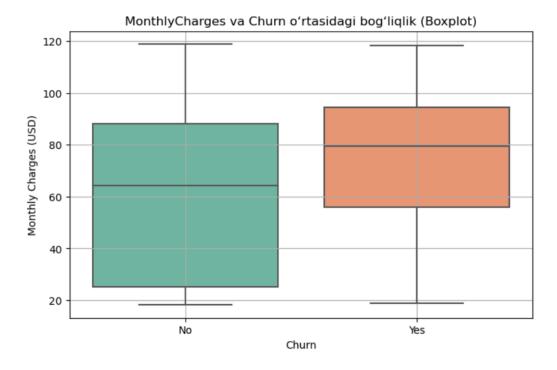
```
plt.title('Churn bo'yicha Tenure taqsimoti (Boxplot)')
plt.xlabel('Churn')
plt.ylabel('Tenure (oylarda)')
plt.grid(True)
plt.show()
```



# 3.2. MonthlyCharges va Churn oʻrtasidagi bogʻliqlik (boxplot)

```
import seaborn as sns
import matplotlib.pyplot as plt

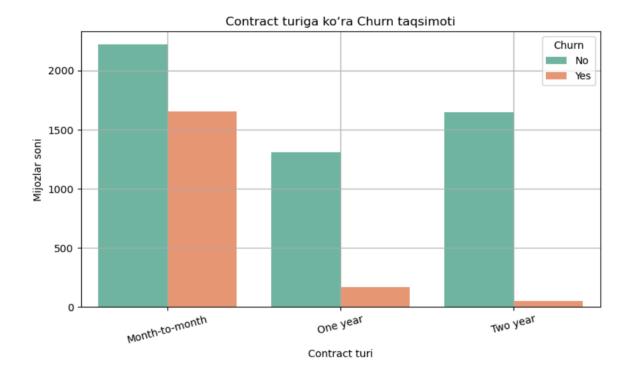
plt.figure(figsize=(8, 5))
sns.boxplot(x='Churn', y='MonthlyCharges', data=df, palette='Set2')
plt.title('MonthlyCharges va Churn o'rtasidagi bog'liqlik (Boxplot)')
plt.xlabel('Churn')
plt.ylabel('Monthly Charges (USD)')
plt.grid(True)
plt.show()
```



## 3.3. Contract turiga koʻra Churn taqsimoti (countplot)

```
import seaborn as sns
import matplotlib.pyplot as plt

plt.figure(figsize=(8, 5))
sns.countplot(data=df, x='Contract', hue='Churn', palette='Set2')
plt.title('Contract turiga ko'ra Churn taqsimoti')
plt.xlabel('Contract turi')
plt.ylabel('Mijozlar soni')
plt.legend(title='Churn')
plt.grid(True)
plt.xticks(rotation=15)
plt.tight_layout()
plt.show()
```



- 4. Ma'lumotlarni tozalash:
- Yetishmayotgan qiymatlar (NaN)
- Notoʻgʻri qiymatlar (??, unknown)
- Noodatiy yoki salbiy qiymatlar (TotalCharges > 10000, tenure < 0)
- Toʻgʻri ma'lumot turlari bilan ishlash

```
import pandas as pd

df = pd.read_csv('data.csv')

df = df.drop(['customerID'], axis=1)

df = df.drop(['gender'], axis=1)

df['MonthlyCharges'] = df['MonthlyCharges'].replace('??', 'NaN')

df['MonthlyCharges'] = df['MonthlyCharges'].astype('float')

df['TotalCharges'] = df['TotalCharges'].replace('??', 'NaN')

df['TotalCharges'] = df['TotalCharges'].replace(' ', 'NaN')
```

```
df['TotalCharges'] = df['TotalCharges'].astype('float')
df['tenure'] = df['tenure'].replace(-1.0, 1.0)
df['tenure'] = df['tenure'].fillna(1.0)
fiber mode = df[df['InternetService'] == 'Fiber
optic']['MonthlyCharges'].mean()
dsl mode = df[df['InternetService'] == 'DSL']['MonthlyCharges'].mean()
no mode = df[df['InternetService'] == 'No']['MonthlyCharges'].mean()
df.loc[(df['InternetService'] == 'Fiber optic') &
(df['MonthlyCharges'].isna()), 'MonthlyCharges'] = fiber mode
df.loc[(df['InternetService'] == 'DSL') & (df['MonthlyCharges'].isna()),
'MonthlyCharges'] = dsl mode
df.loc[(df['InternetService'] == 'No') & (df['MonthlyCharges'].isna()),
'MonthlyCharges'] = no mode
df['TotalCharges'] = pd.to numeric(df['TotalCharges'], errors='coerce')
mask = (df['TotalCharges'].isna()) | (df['TotalCharges'] >
df['MonthlyCharges'] * df['tenure'] * 2)
df.loc[mask, 'TotalCharges'] = df.loc[mask, 'MonthlyCharges'] *
df.loc[mask, 'tenure']
```

#### 1. Keraksiz ustunlarni olib tashlash

- **customerID** har bir mijozga unikal identifikator boʻlgani uchun model uchun foydali emas, olib tashlandi.
- **gender** ushbu ustun asosida tahlil alohida bajarilgan boʻlib, modelga ta'siri past deb baholanib, chiqarib yuborildi.

### 2. Noto'g'ri qiymatlarni aniqlash va tuzatish

- MonthlyCharges va TotalCharges ustunlarida ba'zi qiymatlar '??' yoki bo'sh joy (' ') ko'rinishida ifodalangan bo'lib, ular NaN qiymatiga almashtirildi.
- Ushbu ustunlar **float** (haqiqiy son) formatiga oʻtkazildi.

## 3. tenure ustunidagi gʻayritabiiy qiymatlar

- tenure (kompaniyada qolgan oylar soni) ustunida ayrim qiymatlar -1.0 edi. Bu qiymat mavjud emas deb qabul qilinib, 1.0 ga almashtirildi.
- NaN bo'lgan tenure qiymatlari ham 1.0 bilan to'ldirildi.

### 4. MonthlyCharges ustunidagi NaN qiymatlarni toʻldirish

- MonthlyCharges ustunidagi bo'sh qiymatlar **InternetService** turiga qarab o'rtacha qiymat bilan to'ldirildi:
  - Fiber optic foydalanuvchilari uchun fiber\_mode
  - DSL foydalanuvchilari uchun dsl\_mode
  - **No internet** foydalanuvchilari uchun no\_mode

Bu metod shartli toʻldirish (conditional imputation) usuli hisoblanadi va mavjud bogʻliqlikni saqlashga yordam beradi.

### 5. TotalCharges ustunidagi anomaliyalarni tuzatish

• TotalCharges ustunidagi notoʻgʻri yoki boʻsh qiymatlar aniqlanib:

- o qiymat yoʻq (NaN) boʻlsa yoki
- TotalCharges > MonthlyCharges × tenure × 2 bo'lsa (ya'ni o'zgaruvchilarning fizik mantiqiga zid),
- ularning qiymati TotalCharges = MonthlyCharges ×
   tenure formulasi asosida qayta hisoblab chiqarildi.

## 5. Xususiyatlar bilan ishlash:

- Kategorik ustunlarni kodlash (One-Hot yoki Label Encoding)
- Sonli ustunlarni masshtablash (Scaler orqali)

## 6. Model yaratish:

- Kamida 2 ta modelni sinab koʻring:
- o Logistic Regression
- o Random Forest yoki XGBoost
- Model sifatini quyidagi mezonlar boʻyicha baholang:
- o Accuracy, F1 score, ROC-AUC, confusion matrix

Model o'qitilgan kodi:

#### import pandas as pd

```
import dill
from sklearn.pipeline import Pipeline
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import OneHotEncoder
from sklearn.compose import ColumnTransformer
```

```
from sklearn.model selection import cross val predict, StratifiedKFold
from sklearn.preprocessing import StandardScaler, LabelEncoder
from sklearn.ensemble import RandomForestClassifier
from sklearn.linear model import LogisticRegression
from sklearn.metrics import accuracy_score, f1_score, roc_auc_score,
confusion matrix
from xgboost import XGBClassifier
def main():
   df = pd.read csv('C:/exam/new dataset2.csv')
   x = df.drop('Churn', axis=1)
   y = df['Churn']
   le = LabelEncoder()
   y = le.fit transform(y)
   numerical_features = x.select dtypes(include=['int64',
float64']).columns
   categorical_features = x.select_dtypes(include=['object']).columns
   numerical transformer = Pipeline(steps=[('scaler', StandardScaler())])
   categorical transformer = Pipeline(steps=[('onehot',
OneHotEncoder(handle unknown='ignore'))])
```

```
preprocessor = ColumnTransformer(transformers=[
    ('numerical', numerical transformer, numerical features),
    ('categorical', categorical transformer, categorical features)
models = (
    LogisticRegression(solver='liblinear'),
    RandomForestClassifier(random state=42),
   XGBClassifier(use label encoder=False, eval metric='logloss')
best model name = ""
best pipe = None
results = []
cv = StratifiedKFold(n splits=5, shuffle=True, random state=42)
for model in models:
   pipe = Pipeline(steps=[
        ('preprocessor', preprocessor),
```

```
y pred = cross val predict(pipe, x, y, cv=cv)
roc_auc = roc_auc_score(y, y_pred)
acc = accuracy_score(y, y_pred)
f1 = f1_score(y, y_pred)
cm = confusion matrix(y, y pred)
results.append({
    'model': type(model).__name__,
   best model name = type(model). name
   best_pipe = pipe.fit(x, y)
```

```
for res in results:
   print(f"\nModel: {res['model']}")
   print(f" Accuracy: {res['accuracy']:.4f}")
   print(f" F1 Score: {res['f1']:.4f}")
   print(f" ROC-AUC: {res['roc_auc']:.4f}")
   print(f" Confusion Matrix:\n{res['confusion matrix']}")
if best pipe is not None:
   with open('best model pipeline.dill', 'wb') as f:
        dill.dump(best pipe, f)
   print(f"\nEng yaxshi model '{best model name}' faylga saqlandi.")
```

Ushbu bosqichda mijozlarning xizmatdan voz kechishini (Churn) bashorat qiluvchi model qurildi va sinovdan oʻtkazildi. Jarayon quyidagi qadamlarni oʻz ichiga oladi:

## 1. Ma'lumotlarni yuklash va tayyorlash

• Ma'lumotlar new\_dataset2.csv fayldan o'qildi.

- Belgilangan maqsadli ustun Churn (yoʻq yoki ha).
- Belgilangan maqsadli oʻzgaruvchi LabelEncoder yordamida raqamli formatga oʻtkazildi (0 va 1).

### 2. Xususiyatlarni turkumlash

- Sonli ustunlar: int64, float64 tipidagi ustunlar.
- Kategoriya ustunlari: object tipidagi ustunlar.

## 3. Ma'lumotlarni oldindan qayta ishlash (preprocessing)

- **Sonli ustunlar** uchun StandardScaler ishlatilib, qiymatlar standartlashtirildi (oʻrtacha 0, dispersiya 1 boʻladi).
- **Kategoriya ustunlari** uchun OneHotEncoder qoʻllanilib, nomutanosib kategoriyalar uchun **ignore\_unknown=True** parametri yordamida yangi kategoriyalar paydo boʻlsa xatolik boʻlmasligi ta'minlandi.
- Bu ikki bosqich ColumnTransformer yordamida birlashtirildi.

## 4. Modellarni tayyorlash va solishtirish

- Quyidagi uchta mashhur klassifikatsiya algoritmlari tanlandi:
  - Logistic Regression (liblinear solver bilan)
  - Random Forest Classifier (random\_state=42 bilan)

 XGBoost Classifier (use\_label\_encoder=False va eval\_metric='logloss' parametrlari bilan)

#### 5. Model baholash

- Har bir model uchun 5 ta stratifikatsiyalangan kross-valyadatsiya (StratifiedKFold) bajarildi.
- Har bir qadamda quyidagi metrikalar hisoblandi:
- 1. **Accuracy** toʻgʻri klassifikatsiya ulushi.
- 2. **F1-Score** aniqlik va chaqqonlikning uygʻunligi, ayniqsa sinf nomutanosibligi holatlarida muhim.
- 3. **ROC-AUC** modelning ajrata olish qobiliyatining oʻlchovi.
- 4. **Confusion Matrix** haqiqiy va bashorat qilingan natijalar taqsimoti.

### 6. Eng yaxshi modelni tanlash va saqlash

- Eng yuqori **F1-score** koʻrsatkichiga ega model tanlandi.
- Ushbu model butun ma'lumotlar to'plamida o'qitildi (fit qilindi).
- Natijada yaratilgan Pipeline (preprocessing + model)
   best\_model\_pipeline.dill fayliga saqlandi.

```
Model: LogisticRegression
  Accuracy: 0.8012
  F1 Score: 0.5935
  ROC-AUC: 0.7200
  Confusion Matrix:
[[4621 553]
 [ 847 1022]]
Model: RandomForestClassifier
  Accuracy: 0.7798
  F1 Score: 0.5391
  ROC-AUC: 0.6857
  Confusion Matrix:
[[4585 589]
 [ 962 907]]
Model: XGBClassifier
 Accuracy: 0.7758
 F1 Score: 0.5417
  ROC-AUC: 0.6875
 Confusion Matrix:
[[4531 643]
[ 936 933]]
Eng yaxshi model 'LogisticRegression' faylga saqlandi.
```

# **8.** Oddiy tizim yaratish:

## Variant 1:

Veb-ilova:

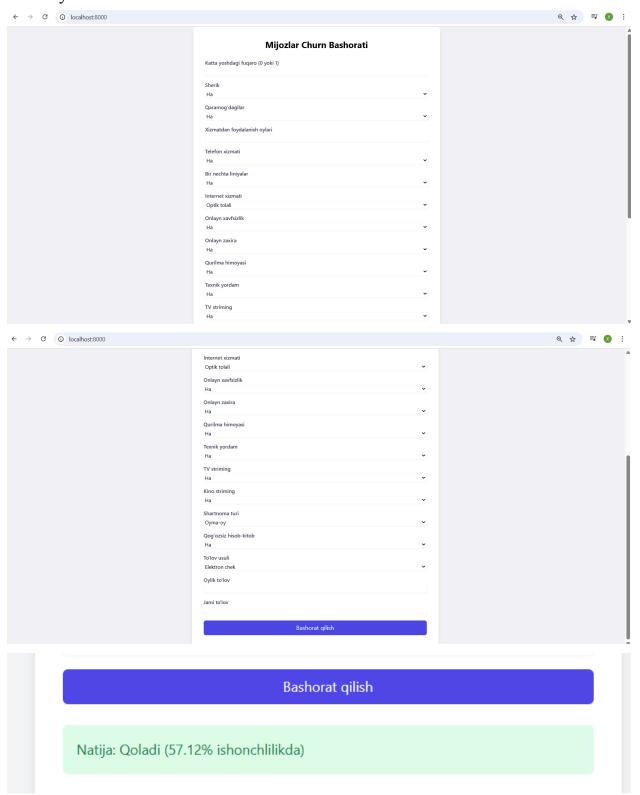
- Mijoz ma'lumotlarini kiritish
- "Bashorat qilish" tugmasi
- Natija: ketadi / ketmaydi + ehtimol foizda

### Variant 2:

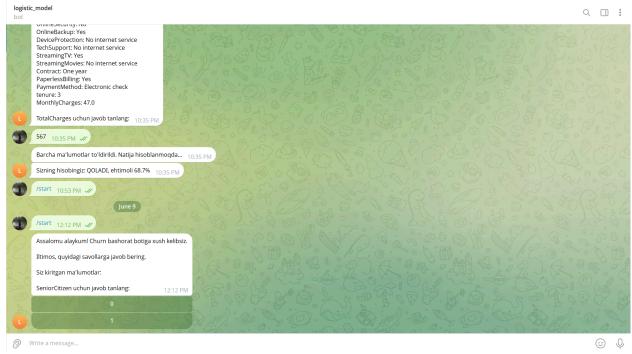
Telegram-bot:

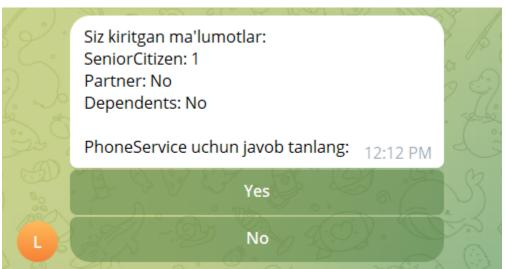
- /predict buyrugʻi orqali ma'lumotlar soʻraladi
- Bot natijani qaytaradi

# Web sayt skrenshoti:



# Telegram bot skrenshoti:





# logistic\_model

bot

